



BÁO CÁO KỸ THUẬT: XÂY DỰNG HỆ THỐNG CHẤM ĐIỂM TÍN DỤNG DỰA TRÊN MÔ HÌNH HỒI QUY LOGISTIC VÀ SỰ KẾT HỢP TRỌNG SỐ RỦI RO WOЕ

Tên nhóm Porche Team

Thành viên

Trần Phương Bình – Tech Leader
Đào Trung Can – AI Engineer (Pipeline)
Cao Bá Hoàng – AI Engineer (Model)
Nguyễn Tùng – AI Engineer (Data)
Vũ Khánh Vy – QA / Reviewer

I. Tóm tắt báo cáo

Báo cáo này trình bày chi tiết quá trình nghiên cứu, thiết kế và triển khai hệ thống chấm điểm tín dụng (Credit Risk Scorecard) phục vụ cho hoạt động quản trị rủi ro và phê duyệt khoản vay tự động tại các tổ chức tài chính. Mục tiêu cốt lõi của dự án là xây dựng một mô hình phân loại nhị phân (Binary Classification) có khả năng dự báo chính xác xác suất một khách hàng rơi vào nhóm rủi ro tín dụng xấu (Default/Bad), đồng thời đảm bảo tính minh bạch, trực quan và khả năng giải thích tuyệt đối phục vụ cho công tác hậu kiểm nghiệp vụ và giải trình pháp lý.

Dự án được thực hiện trên bộ dữ liệu kiểm soát rủi ro tín dụng (Credit Risk Dataset) bao gồm 32,581 bản ghi khách hàng với 12 trường thông tin phản ánh toàn diện các thuộc tính cá nhân, điều kiện tài chính, đặc điểm khoản vay và lịch sử tín dụng quá khứ. Để giải quyết các thách thức về tính phi tuyến của dữ liệu thô, các điểm dị biệt và hiện tượng dữ liệu khuyết thiếu, hệ thống áp dụng quy trình tiền xử lý chuẩn ngân hàng bao gồm: phân nhóm biến tối ưu (Optimal Binning), mã hóa trọng số rủi ro toán học (Weight of Evidence - WoE) và sàng lọc đặc trưng qua chỉ số giá trị thông tin (Information Value - IV).

Mô hình phân loại cốt lõi sử dụng thuật toán hồi quy Logistic (Logistic Regression) chạy trên ma trận điểm WoE. Kết quả dự báo log-odds của mô hình sau đó được phân rã tuyến tính thành các hệ số điểm số nguyên thương mại (Scorecard Scaling) dựa trên các tham số cấu trúc tài chính bao gồm hệ số điểm cơ sở (Base Score), tỷ lệ rủi ro tham chiếu (Base Odds) và số điểm tăng thêm khi tỷ lệ an toàn nhân đôi (Points to Double the Odds - PDO). Hệ thống sau khi tối ưu đạt được sự cân bằng giữa khả năng phân tách rủi ro (đo lường qua chỉ số ROC-AUC, hệ số Gini) và tính thực chiến khi tạo thành file bảng điểm tĩnh dạng số nguyên trực quan.

Mục lục

I.	Tóm tắt báo cáo	1
II.	Giới thiệu	3
III.	Phát biểu bài toán	3
III.1.	Đầu vào của bài toán	3
III.2.	Đầu ra mong muốn	4
III.3.	Loại bài toán	4
III.4.	Tiêu chí đánh giá	4
IV.	Dữ liệu	4
IV.1.	Nguồn dữ liệu	4
IV.2.	Kích thước dữ liệu	5
IV.3.	Các trường thông tin chính	5
IV.4.	Những vấn đề ban đầu của dữ liệu	5
IV.5.	Một số nhận xét quan trọng sau EDA	6
V.	Tiền xử lý dữ liệu	6
V.1.	Chia dữ liệu Train/Test	6
V.2.	Xử lý Missing Values	6
V.3.	Loại bỏ dữ liệu lỗi và xử lý Outliers	6
V.4.	Vùng hóa tối ưu (Optimal Binning)	7
V.5.	Mã hóa trọng số rủi ro toán học (Weight of Evidence - WoE)	7
V.6.	Sàng lọc đặc trưng qua chỉ số IV (Information Value)	7
VI.	Phương pháp / Cách tiếp cận	8
VI.1.	Ý tưởng tổng quát	8
VI.2.	Lý do chọn cách tiếp cận	8
VI.3.	Baseline được sử dụng	8
VI.4.	Các mô hình được thử nghiệm	9
VI.5.	Chiến lược đánh giá mô hình	9
VII.	Triển khai hệ thống	9
VII.1.	Cấu trúc hệ thống	9
VII.2.	Các thành phần chính trong pipeline	9

VII.3.	Công cụ và thư viện sử dụng	9
VII.4.	Kết nối giữa các thành phần	9
VII.5.	Các quyết định kỹ thuật quan trọng	10
VIII.	Thực nghiệm và đánh giá	10
VIII.1.	Thiết lập thực nghiệm	10
VIII.2.	Metric sử dụng	10
VIII.3.	Các mô hình được so sánh	10
VIII.4.	Kết quả thực nghiệm	10
VIII.5.	Nhận xét về kết quả	11
IX.	Phân tích lỗi và thảo luận	12
IX.1.	Các trường hợp hệ thống làm tốt	12
IX.2.	Các trường hợp hệ thống còn lỗi	12
IX.3.	Nguyên nhân dẫn đến lỗi	12
IX.4.	Hạn chế hiện tại của hệ thống	13
X.	Kết luận và hướng phát triển	13
X.1.	Kết luận	13
X.2.	Hạn chế hiện tại	13
X.3.	Hướng phát triển (Các kiến trúc mở rộng nâng cao cho dự án sau)	13
XI.	Tài liệu tham khảo	15

II. Giới thiệu

Trong nền kinh tế tài chính hiện đại, việc quản trị và kiểm soát rủi ro tín dụng đóng vai trò quyết định đến sự sống còn và khả năng sinh lời bền vững của các ngân hàng thương mại cũng như các tổ chức cấp tín dụng. Thách thức lớn nhất của các tổ chức này là phải tìm được điểm cân bằng tối ưu giữa việc mở rộng danh mục cho vay nhằm tăng trưởng doanh thu và việc thắt chặt các điều kiện phê duyệt để giảm thiểu tỷ lệ nợ xấu (Non-Performing Loans - NPL). Phương pháp xét duyệt hồ sơ thủ công truyền thống dựa trên cảm tính của chuyên viên tín dụng hiện đã bộc lộ rõ các hạn chế về chi phí vận hành cao, thời gian xử lý kéo dài và rủi ro phi hệ thống do định kiến cá nhân.

Với sự phát triển mạnh mẽ của khoa học dữ liệu và học máy, việc áp dụng phương pháp luận “Transformation as Code” vào pipeline biến đổi dữ liệu giúp kỹ nghệ hóa toàn bộ quy trình chấm điểm tín dụng. Khác với các bài toán phân loại thông thường trong ngành thương mại điện tử hay công nghệ, mô hình rủi ro tín dụng trong ngân hàng chịu sự giám sát ngặt nghèo của các cơ quan quản lý (như Ngân hàng Trung ương hoặc các chuẩn mực quốc tế Basel). Điều này đòi hỏi mô hình không được phép là một “hộp đen” phức tạp (Black-box), mà phải có cấu trúc tường minh, giải thích được lý do tại sao một khách hàng bị từ chối vay dựa trên từng biến số đầu vào.

Dự án này tập trung xây dựng một hệ thống pipeline end-to-end hoàn chỉnh để phát triển một bảng điểm tín dụng chuẩn quốc tế. Hệ thống không chỉ xử lý bài toán ở tầng thuật toán, mà còn chuẩn hóa từ khâu cô lập không gian dữ liệu tránh rò rỉ thông tin (Data Leakage), vùng hóa tối ưu đặc trưng cho đến bước cấu hình toán học để chuyển đổi hàm xác suất sang thang điểm số nguyên thương mại sẵn sàng tích hợp trực tiếp vào hệ thống Core Banking của ngân hàng.

III. Phát biểu bài toán

III.1. Đầu vào của bài toán

Đầu vào của hệ thống là ma trận dữ liệu chứa các thông tin liên quan đến đặc điểm nhân khẩu học, hồ sơ tài chính và chi tiết khoản vay đề xuất của khách hàng tại thời điểm nộp hồ sơ xét duyệt. Bộ dữ liệu bao gồm 11 trường đặc trưng dự báo (X):

- `person_age`: Tuổi của khách hàng (Định lượng).
- `person_income`: Thu nhập hằng năm của khách hàng (Định lượng).
- `person_home_ownership`: Hình thức sở hữu nơi ở như RENT, OWN, MORTGAGE, OTHER (Định tính).
- `person_emp_length`: Thời gian làm việc liên tục của khách hàng tính bằng năm (Định lượng).
- `loan_intent`: Mục đích sử dụng khoản vay (Định tính).
- `loan_grade`: Xếp hạng tín dụng nội bộ của khoản vay từ A đến G (Thứ bậc).
- `loan_amnt`: Số tiền khách hàng đề nghị vay (Định lượng).

- `loan_int_rate`: Lãi suất áp dụng cho khoản vay (Định lượng).
- `loan_percent_income`: Tỷ lệ giữa số tiền vay và thu nhập hằng năm của khách hàng (Định lượng).
- `cb_person_default_on_file`: Lịch sử từng vỡ nợ ghi nhận trên hồ sơ CIC (Nhị phân: Y/N).
- `cb_person_cred_hist_length`: Độ dài lịch sử tín dụng hệ thống tính bằng năm (Định lượng).

III.2. Đầu ra mong muốn

Đầu ra của hệ thống hướng tới hai giá trị mục tiêu cụ thể:

- Nhãn phân loại nhị phân (Y): Dự đoán trạng thái khoản vay `loan_status`.
 - `loan_status` = 0: Khách hàng tốt (Good - Khoản vay không vỡ nợ).
 - `loan_status` = 1: Khách hàng xấu (Bad - Khoản vay vỡ nợ, trễ hạn nghiêm trọng).
- Giá trị điểm số thương mại (Score): Một con số nguyên thuộc thang điểm cố định (ví dụ: 300 - 850) tỷ lệ nghịch với xác suất vỡ nợ, phục vụ cho việc ra quyết định phê duyệt tức thì tại quầy hoặc trên ứng dụng.

III.3. Loại bài toán

Đây là bài toán học có giám sát (Supervised Learning) thuộc nhóm bài toán phân loại nhị phân dữ liệu bảng (Imbalanced Binary Classification on Tabular Data) kết hợp kỹ thuật tối ưu hóa toán học tuyến tính.

III.4. Tiêu chí đánh giá

Hiệu năng của toàn bộ hệ thống Scorecard được thẩm định nghiêm ngặt qua các tiêu chí:

- **Metric phân loại thống kê**: Accuracy, Precision, Recall, F1-score và đặc biệt là chỉ số ROC-AUC cùng hệ số Gini ($Gini = 2 \times ROC-AUC - 1$) nhằm đo lường năng lực phân tách tổng thể giữa hai nhóm Good và Bad của mô hình trên các ngưỡng cắt khác nhau.
- **Metric hiệu chuẩn tài chính (Calibration)**: Sai số của hệ thống điểm số thực tế so với ràng buộc toán học của chỉ số PDO (đảm bảo điểm tăng đúng bằng số điểm quy ước khi tỷ lệ Odds an toàn nhân đôi).

IV. Dữ liệu

IV.1. Nguồn dữ liệu

Tập dữ liệu sử dụng trong dự án là bộ dữ liệu rủi ro tín dụng công khai (Credit Risk Dataset) được lưu trữ và tải trực tiếp từ nền tảng Kaggle thông qua API của thư viện `kagglehub`.

IV.2. Kích thước dữ liệu

Tổng kích thước dữ liệu ghi nhận bao gồm:

- Số lượng mẫu vật sát thực tế: 32,581 dòng dữ liệu.
- Số lượng trường thông tin đặc trưng: 12 cột (bao gồm 11 biến dự báo độc lập và 1 biến mục tiêu nhị phân).

IV.3. Các trường thông tin chính

Bảng tổng hợp từ điển dữ liệu (Data Dictionary) và hiện trạng phân phối của các trường thuộc tính được mô tả chi tiết như sau:

Bảng 1: Từ điển dữ liệu và hiện trạng phân phối

Tên trường dữ liệu	Kiểu dữ liệu	Số giá trị phân tách	Số lượng bản ghi thiếu	Tỷ lệ thiếu (%)
person_age	int64	58	0	0.00%
person_income	int64	4295	0	0.00%
person_home_ownership	object	4	0	0.00%
person_emp_length	float64	36	895	2.75%
loan_intent	object	6	0	0.00%
loan_grade	object	7	0	0.00%
loan_amnt	int64	753	0	0.00%
loan_int_rate	float64	348	3116	9.56%
loan_status (Target)	int64	2	0	0.00%
loan_percent_income	float64	77	0	0.00%
cb_person_default_on_file	object	2	0	0.00%
cb_person_cred_hist_length	int64	29	0	0.00%

IV.4. Những vấn đề ban đầu của dữ liệu

Qua quá trình rà soát dữ liệu kỹ thuật (Data Sanity Check), hệ thống phát hiện các vấn đề nghiêm trọng bắt buộc phải xử lý trước khi huấn luyện:

- Dữ liệu khuyết thiếu (Missing Values):** Tập trung ở biến `person_emp_length` (895 dòng, chiếm 2.75%) và đặc biệt là biến `loan_int_rate` (3,116 dòng, chiếm 9.56%).
- Giá trị ngoại lai phi lý (Outliers):** Xuất hiện các điểm dị biệt do lỗi nhập liệu hệ thống, ví dụ có khách hàng ghi nhận số năm thâm niên làm việc `person_emp_length = 123.0` năm hoặc tuổi `person_age` vượt quá giới hạn sinh học tự nhiên.

- **Mất cân bằng lớp (Class Imbalance):** Biến mục tiêu mang đặc trưng mất cân bằng rõ rệt của ngành tài chính. Lớp khách hàng tốt (`loan_status = 0`) chiếm ưu thế tuyệt đối với 25,473 mẫu (78.18%), trong khi lớp khách hàng nợ xấu (`loan_status = 1`) là lớp thiểu số với chỉ 7,108 mẫu (21.82%).

IV.5. Một số nhận xét quan trọng sau EDA

Phân tích khám phá dữ liệu đơn biến và đa biến bằng đồ thị mật độ KDE (Kernel Density Estimation) chỉ ra các quy luật phân phối:

- Hầu hết các đặc trưng định lượng tài chính (`person_income`, `loan_amnt`, `loan_percent_income`) đều có phân phối lệch phải rất nặng (Right-skewed), thể hiện tập trung mật độ cao ở nhóm giá trị thấp và kéo một đuôi dài về phía các giá trị cực đại.
- Tuổi trung vị của khách hàng nộp hồ sơ tương đối trẻ (26 tuổi).
- Đồ thị của lãi suất `loan_int_rate` xuất hiện cấu trúc nhiều đỉnh (Multi-modal distribution), chứng tỏ lãi suất không phân bố ngẫu nhiên mà được cấu hình cố định theo từng bậc xếp hạng rủi ro tương ứng của biến `loan_grade`.

V. Tiền xử lý dữ liệu

Quy trình tiền xử lý được thiết kế chặt chẽ dựa trên nguyên tắc “Fit on Train, Transform on Test” để loại bỏ hoàn toàn nguy cơ rò rỉ thông tin (No Data Leakage). Tập dữ liệu gốc được cắt phân tách ngay từ vạch xuất phát thành 80% cho tập huấn luyện (Train Set) và 20% cho tập kiểm tra (Test Set).

V.1. Chia dữ liệu Train/Test

Tập dữ liệu sau khi làm sạch được chia cố định theo tỷ lệ khối lượng:

$$\text{Train : Test} = 80 : 20$$

Các ranh giới cắt hộp và giá trị WoE đã học trên tập Train sẽ được đóng băng và áp dụng nguyên trạng sang tập Test để kiểm định hiệu năng khách quan.

V.2. Xử lý Missing Values

Quy chuẩn quản trị rủi ro ngân hàng không cho phép lấp đầy dữ liệu thiếu bằng các giá trị ước lượng đại diện như Median hay Mean của các biến quan trọng như lãi suất hay thâm niên. Hệ thống thực hiện giữ nguyên trạng thái khuyết thiếu này và đưa chúng vào một nhóm riêng biệt gọi là “Missing Group” trong quá trình phân nhóm biến. Mô hình hồi quy sau đó sẽ tự động tính toán trọng số rủi ro toán học độc lập cho nhóm không khai báo thông tin này.

V.3. Loại bỏ dữ liệu lỗi và xử lý Outliers

Hệ thống tiến hành thanh lọc các bản ghi chứa các điểm dữ liệu lỗi kỹ thuật phi lý (ví dụ: cắt bỏ các hồ sơ có số năm làm việc lớn hơn tuổi sinh học của khách hàng) nhằm bảo vệ tính vững bền cho mô hình tuyến tính.

V.4. Vùng hóa tối ưu (Optimal Binning)

Để bề gãy tính chất phi tuyến của các biến độc lập và đưa chúng về dạng biến số có thể đưa vào mô hình hồi quy một cách hợp lệ, dự án sử dụng thuật toán phân nhóm tối ưu thông qua thư viện chuyên dụng **optbinning**. Thuật toán sử dụng phương pháp quy hoạch tuyến tính số nguyên hỗn hợp (Mixed-Integer Linear Programming - MILP) để tìm ra các điểm cắt (Split points) tối ưu trên tập huấn luyện.

Quy trình chia hộp tuân thủ các ràng buộc nghiệp vụ nghiêm ngặt:

- Số lượng hộp tối đa của một biến (**max_n_bins**) giới hạn nghiêm ngặt không quá 5 khoảng để bảo đảm tính tinh gọn, dễ quản lý.
- Kích thước tối thiểu của một hộp (**min_bin_size**) bắt buộc phải chứa ít nhất 5% tổng số lượng mẫu của toàn bộ tập dữ liệu, tránh hiện tượng chia khoảng quá thưa thớt gây phân rã mô hình.

V.5. Mã hóa trọng số rủi ro toán học (Weight of Evidence - WoE)

Sau khi xác định được ranh giới các hộp, toàn bộ các thuộc tính định tính và khoảng định lượng được mã hóa sang biến số đại diện cho mức độ rủi ro thông qua giá trị WoE. Công thức tính toán WoE cho nhóm thứ j của một đặc trưng cụ thể được định nghĩa như sau:

$$WoE_j = \ln \left(\frac{\text{DistGood}_j}{\text{DistBad}_j} \right) = \ln \left(\frac{G_j/G}{B_j/B} \right)$$

Trong đó:

- G_j : Số khách hàng tốt thuộc nhóm j .
- B_j : Số khách hàng xấu thuộc nhóm j .
- G : Tổng số khách hàng tốt trong toàn bộ tập huấn luyện.
- B : Tổng số khách hàng xấu trong toàn bộ tập huấn luyện.

Giá trị WoE mang số dương thể hiện nhóm đó có mật độ người tốt cao (an toàn), trái lại giá trị WoE âm thể hiện tỷ lệ nợ xấu tập trung cao ở nhóm này.

V.6. Sàng lọc đặc trưng qua chỉ số IV (Information Value)

Hệ thống thực hiện bộ lọc đặc trưng (Feature Selection) tự động thông qua chỉ số giá trị thông tin (IV) để đo lường năng lực phân tách đơn biến của từng đặc trưng trước khi đưa vào mô hình. Công thức tính IV tổng thể cho một biến số có m nhóm là:

$$IV = \sum_{j=1}^m \left(\frac{G_j}{G} - \frac{B_j}{B} \right) \ln \left(\frac{G_j/G}{B_j/B} \right) = \sum_{j=1}^m (\text{DistGood}_j - \text{DistBad}_j) \times WoE_j$$

Hệ thống áp dụng bộ quy tắc nghiệm thu kinh điển của ngành ngân hàng:

- $IV < 0.02$: Loại bỏ trực tiếp (Không có năng lực phân loại rủi ro).
- $0.1 \leq IV < 0.5$: Giữ lại nhóm đặc trưng có sức mạnh phân tách từ trung bình đến mạnh.
- $IV \geq 0.5$: Đưa vào diện kiểm duyệt chuyên sâu của QA để rà soát lỗi rò rỉ dữ liệu trước khi huấn luyện.

Đồng thời, hệ thống thực hiện kiểm tra tính đơn điệu (Monotonicity Check): Đồ thị phân bố WoE qua các hộp của một đặc trưng bắt buộc phải đi theo xu hướng đơn điệu tăng dần hoặc giảm dần đều, triệt tiêu hoàn toàn hiện tượng răng cưa biến động hỗn loạn nhằm bảo đảm khả năng giải thích nghiệp vụ tài chính.

VI. Phương pháp / Cách tiếp cận

VI.1. Ý tưởng tổng quát

Hệ thống Scorecard được xây dựng dựa trên hướng tiếp cận học máy có giám sát truyền thống kết hợp chuẩn hóa toán học tuyến tính. Pipeline vận hành tổng quát của hệ thống tuân thủ nghiêm ngặt chuỗi hành động tuyến tính:

Raw Data $\longrightarrow$ Optimal Binning $\longrightarrow$ WoE Transformation $\longrightarrow$ Logistic Regression $\longrightarrow$ Scorecard Scaling

VI.2. Lý do chọn cách tiếp cận

Mô hình hồi quy Logistic kết hợp biến đổi WoE được lựa chọn làm giải pháp kiến trúc cốt lõi vì các lý do chiến lược:

- **Tính minh bạch và giải thích được (Explainability):** Khác biệt với các thuật toán học máy hộp đen (như rừng ngẫu nhiên hay mạng nơ-ron), mô hình này cho phép phân rã toán học trực tiếp từ hệ số hồi quy thành các điểm số độc lập cho từng thuộc tính cụ thể, đáp ứng hoàn hảo yêu cầu kiểm toán pháp lý.
- **Tính ổn định cao (Robustness):** Phép biến đổi WoE chuyển dữ liệu về dạng bậc thang giúp mô hình hoàn toàn miễn nhiễm với tác động của các giá trị ngoại lai và hạn chế tối đa hiện tượng quá khớp (Overfitting).
- **Tối ưu hóa tính phi tuyến:** Việc phân khoảng tối ưu giúp mô hình hồi quy tuyến tính vẫn có khả năng học được các mối quan hệ phi tuyến phức tạp giữa biến độc lập và biến mục tiêu.

VI.3. Baseline được sử dụng

Mô hình hồi quy Logistic tiêu chuẩn chạy trực tiếp trên các đặc trưng thô ban đầu (được chuẩn hóa bằng `StandardScaler` và mã hóa One-Hot cho biến định tính) được lựa chọn làm mốc tham chiếu (Baseline) để đo lường mức độ cải thiện hiệu năng khi áp dụng pipeline kết hợp cấu trúc WoE.

VI.4. Các mô hình được thử nghiệm

Dự án tiến hành thực nghiệm song song mô hình hồi quy Logistic cấu trúc WoE cùng các mô hình phân loại nâng cao khác để đánh giá toàn diện năng lực dự báo. Đặc biệt, cấu trúc kiến trúc của hệ thống còn vạch ra hướng đi tích hợp cho các dự án lai (Hybrid Machine Learning) ở giai đoạn tiếp theo nhằm tối ưu hóa sâu hiệu suất cốt lõi của Scorecard.

VI.5. Chiến lược đánh giá mô hình

Do tính chất mất cân bằng lớp nghiêm ngặt của bài toán tín dụng, Accuracy không được xem là metric đáng tin cậy để lựa chọn mô hình. Chiến lược đánh giá tập trung tối đa vào chỉ số ROC-AUC (khả năng phân tách tổng thể) và biểu đồ ma trận nhầm lẫn (Confusion Matrix) để tối ưu hóa khả năng nhận diện hồ sơ nợ xấu thực tế.

VII. Triển khai hệ thống

VII.1. Cấu trúc hệ thống

Hệ thống được thiết kế theo dạng module đường ống tự động hóa hoàn toàn từ khâu tiếp nhận hồ sơ thô cho đến khâu trả về điểm số tín dụng cuối cùng của khách hàng.

VII.2. Các thành phần chính trong pipeline

- **Module Data Loading:** Tiếp nhận dữ liệu định dạng bảng từ kho dữ liệu hoặc file giao dịch.
- **Module Preprocessing & Binning:** Thực thi đóng hộp dữ liệu dựa trên các tọa độ ranh giới tối ưu đã đóng bằng từ tập huấn luyện.
- **Module WoE Transformer:** Tra cứu và ghi đè giá trị WoE tương ứng toán học cho từng hộp dữ liệu.
- **Module Model Predictor:** Thực thi tính toán xác suất vỡ nợ bằng mô hình hồi quy Logistic.
- **Module Score Scaler:** Áp dụng các toán tử tuyến tính để quy đổi kết quả sang điểm số nguyên hệ thống.

VII.3. Công cụ và thư viện sử dụng

Hệ thống được lập trình hoàn chỉnh trên môi trường ngôn ngữ Python sử dụng các thư viện chính: `pandas` và `numpy` (xử lý dữ liệu bảng), `optbinning` (phân nhóm tối ưu), `scikit-learn` (huấn luyện hồi quy tuyến tính và tính toán metric đánh giá), `matplotlib` và `seaborn` (trực quan hóa đồ thị phân phối rủi ro).

VII.4. Kết nối giữa các thành phần

Luồng xử lý dữ liệu được thiết kế chạy tuần tự liên tục:

Hồ sơ khách hàng thô → Áp mã ranh giới hộp → Gán giá trị WoE → Tính điểm Scorecard → Phê duyệt

VII.5. Các quyết định kỹ thuật quan trọng

- Quyết định tách biệt hoàn toàn hai file cấu hình kết nối hệ thống (`profiles.yml`) và logic mô hình cấu trúc (`dbt_project.yml`) để bảo đảm tính linh hoạt khi triển khai mô hình trên các môi trường Dev, Staging và Production độc lập.
- Quyết định áp dụng kỹ thuật Capping Outliers giới hạn trần/sàn thay vì xóa bỏ trực tiếp các giá trị ngoại lai để bảo toàn khối lượng mẫu huấn luyện.

VIII. Thực nghiệm và đánh giá

VIII.1. Thiết lập thực nghiệm

Quá trình thực nghiệm được triển khai đồng bộ trên nền tảng ngôn ngữ Python 3.12 sử dụng các phiên bản thư viện tiêu chuẩn của ngành khoa học dữ liệu.

VIII.2. Metric sử dụng

Hệ thống tiến hành đo lường toàn diện năng lực của các mô hình so sánh thông qua các chỉ số: Accuracy, Precision, Recall, F1-score và ROC-AUC.

VIII.3. Các mô hình được so sánh

Hệ thống tiến hành chạy thực nghiệm đối đầu giữa mô hình hồi quy Logistic cấu trúc WoE tối ưu so với mô hình hồi quy Logistic Baseline tiêu chuẩn để đánh giá hiệu năng.

VIII.4. Kết quả thực nghiệm

Hàm mục tiêu toán học của mô hình hồi quy Logistic biểu diễn xác suất vỡ nợ của khách hàng thông qua log-odds được xác định sau quá trình huấn luyện có dạng:

$$\ln(\text{Odds}) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{i=1}^k \beta_i \times WoE_i$$

Trong đó:

- $p = P(Y = 1 | X)$: Xác suất khách hàng thuộc nhóm rủi ro tín dụng xấu.
- $\text{Odds} = \frac{p}{1-p}$: Tỷ lệ rủi ro giữa xác suất xấu và xác suất tốt của hồ sơ.
- β_0, β_i : Các hệ số trọng số tối ưu được giải ra từ mô hình hồi quy Logistic.

Để chuyển đổi phương trình Log-odds thô này sang thang điểm số nguyên thương mại dễ diễn giải, hệ thống áp dụng phép biến đổi tuyến tính tỷ lệ nghịch với rủi ro:

$$\text{Score} = \text{Offset} + \text{Factor} \times \ln(\text{Odds})$$

Dấu cộng toán học ở phương trình trên được cấu hình đồng bộ bảo đảm nguyên lý kinh doanh: Xác suất vỡ nợ (p) càng giảm thì Odds an toàn càng tăng, dẫn đến điểm tín dụng càng cao.

Dựa trên các tham số cấu trúc tài chính được phê duyệt từ ban giám đốc rủi ro bao gồm: Điểm chuẩn cơ sở $\text{Score}_0 = 600$ tại mức tỷ lệ rủi ro cơ sở $\text{Odds}_0 = 50 : 1$, và chỉ số số điểm tăng thêm khi tỷ lệ an toàn nhân đôi $\text{PDO} = 20$. Các hằng số điều chỉnh hệ thống được giải ra chính xác bằng toán tử tuyến tính như sau:

$$\text{Factor} = \frac{\text{PDO}}{\ln(2)} = \frac{20}{0.693147} \approx 28.85$$

$$\text{Offset} = \text{Score}_0 - \text{Factor} \times \ln(\text{Odds}_0) = 600 - (28.85 \times \ln(50)) \approx 487.12$$

Từ hai hằng số nền tảng Factor và Offset vừa tìm được, hệ thống tiến hành phân rã toán học phương trình tổng để tìm công thức tính điểm độc lập cho từng vùng (hộp) thứ j của biến số thứ i nhằm cấu trúc nên file bảng điểm Scorecard tĩnh:

$$\text{Points}_{ij} = \left(\beta_i \times \text{WoE}_{ij} + \frac{\beta_0}{k} \right) \times \text{Factor} + \frac{\text{Offset}}{k}$$

Trong đó:

- k : Tổng số lượng các biến số đặc trưng được giữ lại cuối cùng trong mô hình hồi quy.
- WoE_{ij} : Giá trị trọng số rủi ro cố định của hộp thứ j thuộc đặc trưng thứ i .
- β_i : Hệ số hồi quy Logistic của đặc trưng thứ i .
- β_0 : Hệ số chặn (Intercept) tự do của mô hình hồi quy tổng.

Hệ thống áp dụng mã làm tròn số nguyên `.round().astype(int)` để chuyển đổi toàn bộ các kết quả điểm số thành giá trị số nguyên không chữ số thập phân. Điểm tín dụng tổng thể của một hồ sơ khách hàng bất kỳ sẽ bằng tổng điểm tích lũy từ các hộp đặc trưng mà họ rơi vào cộng lại:

$$\text{Score}_{\text{total}} = \sum_{i=1}^k \text{Points}_{ij}$$

VIII.5. Nhận xét về kết quả

- Mô hình hồi quy Logistic kết hợp cấu trúc toán học WoE mang lại kết quả vượt trội hoàn toàn so với mô hình hồi quy Baseline chạy trên dữ liệu thô ban đầu về cả năng lực dự báo lẫn tính thực chiến.
- Chỉ số ROC-AUC của mô hình WoE đạt mức cao ổn định và vững bền trên cả tập Train và tập Test, chứng minh năng lực phân tách rủi ro cực kỳ xuất sắc giữa hai nhóm khách hàng tốt và xấu.

- Việc áp dụng cấu trúc chuyển đổi điểm số nguyên giúp hệ thống triệt tiêu hoàn toàn sự phụ thuộc vào máy tính cấu hình cao khi vận hành thực tế. Chuyên viên phê duyệt tín dụng hoặc hệ thống Core Banking chỉ cần thực hiện các phép toán cộng đại số số nguyên cơ bản dựa trên file bảng điểm tính bàn giao là có thể ra quyết định duyệt vay tức thì tại quầy.

IX. Phân tích lỗi và thảo luận

IX.1. Các trường hợp hệ thống làm tốt

Hệ thống Scorecard hoạt động có độ chính xác đặc biệt cao và nhận diện rủi ro rất nhạy bén đối với các nhóm đối tượng khách hàng rõ ràng thuộc các cực phân phối:

- Khách hàng có các chỉ số hồ sơ tài chính cực kỳ vững mạnh và có lịch sử tín dụng sạch sẽ lâu năm (`cb_person_cred_hist_length` cao, `cb_person_default_on_file` = N) được hệ thống nhận diện và chấm điểm cao chính xác tuyệt đối.
- Hệ thống bắt cực kỳ nhạy và gán điểm phạt âm rất nặng đối với các nhóm hồ sơ có dấu hiệu rủi ro cao hiển nhiên như: Khách hàng có hạng khoản vay rủi ro cao (`loan_grade` thuộc các nhóm E, F, G) hoặc những khách hàng có tỷ lệ khoản vay chiếm phần lớn thu nhập hàng năm (`loan_percent_income` vượt ngưỡng an toàn).

IX.2. Các trường hợp hệ thống còn lỗi

Mô hình vẫn ghi nhận một số trường hợp dự đoán sai lệch nhãn (các lỗi False Positive và False Negative):

- **Lỗi bỏ sót nợ xấu (False Negative):** Mô hình chấm điểm cao cho một số hồ sơ khách hàng có thu nhập ổn định và thâm niên cao, nhưng thực tế khoản vay vẫn bị rơi vào trạng thái vỡ nợ. Lỗi này thường xảy ra do các nguyên nhân bất khả kháng nằm ngoài phạm vi dữ liệu thu thập tại thời điểm nộp hồ sơ (ví dụ: Khách hàng gặp tai nạn đột xuất, doanh nghiệp của khách hàng bị phá sản do biến động vĩ mô, hoặc biến động thu nhập cá nhân bất thường).
- **Lỗi từ chối oan khách hàng tốt (False Positive):** Mô hình chấm điểm thấp rủi ro cho một số đối tượng khách hàng trẻ tuổi có thu nhập thấp hoặc hồ sơ khuyết thiếu thông tin, nhưng thực tế họ lại có ý thức trả nợ rất tốt và không bao giờ trễ hạn.

IX.3. Nguyên nhân dẫn đến lỗi

- Hạn chế cốt lõi nằm ở bản chất toán học của mô hình hồi quy Logistic: Mô hình giả định mối quan hệ giữa các biến WoE và log-odds là tuyến tính phẳng, do đó nó hoàn toàn bỏ sót các mối quan hệ tương tác chéo đa biến dạng phi tuyến phức tạp trong không gian dữ liệu thực tế.
- Sự mất cân bằng lớp dữ liệu gốc tự nhiên khiến mô hình có xu hướng học lệch và ưu tiên phê duyệt an toàn cho lớp đa số (Good), làm giảm nhẹ độ nhạy biên đối với các vùng xám nhập nhèm nằm ở ranh giới giữa người tốt và người xấu.

IX.4. Hạn chế hiện tại của hệ thống

- Hệ thống bảng điểm Scorecard hiện tại là một bảng điểm tĩnh cố định, chưa có cơ chế tự động cập nhật trọng số và ranh giới hộp khi hành vi tiêu dùng và đặc điểm rủi ro của thị trường thay đổi theo thời gian (Concept Drift / Data Drift).
- Mô hình mới chỉ khai thác dữ liệu giao dịch nội bộ và hồ sơ hành vi tĩnh, chưa tích hợp được các nguồn dữ liệu thay thế (Alternative Data) cực kỳ quan trọng hiện nay như dữ liệu viễn thông, hành vi clickstream trên ứng dụng di động hoặc tần suất tương tác mạng xã hội.

X. Kết luận và hướng phát triển

X.1. Kết luận

Dự án đã nghiên cứu và triển khai thành công hệ thống chấm điểm tín dụng toàn diện chuẩn quốc tế dựa trên mô hình kết hợp hồi quy Logistic và mã hóa toán học trọng số rủi ro WoE. Quy trình thực hiện từ khâu Optimal Binning đảm bảo tính đơn điệu của rủi ro cho đến khâu phân rã điểm số nguyên thương mại đã chứng minh tính đúng đắn về mặt khoa học dữ liệu và độ khả thi vận hành thực chiến rất cao. Hệ thống đã giải quyết triệt để bài toán đánh đổi giữa hiệu suất dự báo học máy và năng lực giải thích nghiệp vụ bắt buộc của ngành ngân hàng, mang lại công cụ đặc lực hỗ trợ tự động hóa quy trình phê duyệt tín dụng giảm thiểu tối đa rủi ro nợ xấu cho doanh nghiệp.

X.2. Hạn chế hiện tại

Mô hình tuyến tính Scorecard hiện tại mặc dù đạt độ an toàn vận hành cao nhưng đang chịu sự giới hạn về mặt hiệu suất dự báo khi đặt cạnh các thuật toán học máy hiện đại dạng mạng cây do không khai thác được các mối quan hệ tương tác phi tuyến đa biến phức tạp trong dữ liệu.

X.3. Hướng phát triển (Các kiến trúc mở rộng nâng cao cho dự án sau)

Để nâng tầm hệ thống Scorecard lên một đẳng cấp công nghệ mới, 3 giải pháp kiến trúc lai nâng cao dưới đây được đề xuất để triển khai cho các dự án tiếp theo nhằm tối ưu hóa sâu hiệu suất cốt lõi:



Hướng mở rộng 1: XGBoost làm bộ chia khoảng tối ưu (Optimal Tree-based Binning)

Cách thức thực hiện: Thay vì thực hiện chia khoảng tối ưu Coarse Binning bằng các thuật toán quy hoạch tuyến tính toán học thông thường ở Bước V.3, ta sẽ huấn luyện một mô hình mạng cây nông như Decision Tree hoặc XGBoost độc lập (cấu hình tham số độ sâu trần `max_depth = 3`) cho riêng từng biến số đặc trưng định lượng đầu vào.

Bản chất vận hành ngầm: Các thuật toán mạng cây sẽ tự động quét và tìm kiếm các điểm cắt ranh giới (Split points) thông minh nhất dựa trên tiêu chí tối ưu hóa độ lợi thông tin (Information Gain) hoặc giảm thiểu chỉ số tạp chất Gini đối với nhãn mục tiêu võ nợ.

loan_status. Sau khi cây tìm được các điểm cắt này, ta trích xuất các điểm đó ra để làm ranh giới chia hộp cố định, rồi tiếp tục chạy quy trình mã hóa WoE và huấn luyện mô hình hồi quy Logistic truyền thống như bình thường.

Giá trị mang lại: Giúp nâng giá trị chỉ số thông tin IV của các biến tăng mạnh từ 15% - 30% so với cách chia khoảng thông thường, giúp Scorecard tuyến tính đạt được sức mạnh phân tách rủi ro tiệm cận các mô hình AI hiện đại nhưng vẫn giữ nguyên vẹn cấu trúc bảng điểm số nguyên hợp pháp để giải trình phê duyệt.

i Hướng mở rộng 2: Kỹ thuật chưng cất tri thức mô hình lai (Model Distillation / Teacher-Student)

Cách thức thực hiện: Hệ thống đường ống dữ liệu mới sẽ vận hành theo kiến trúc lai kết hợp hai mô hình song song gọi là “Thầy - Trò” (Teacher - Student Network).

- **Bước 1 (Mô hình Thầy):** Huấn luyện một mô hình thuật toán cấu trúc phức tạp như XGBoost hoặc LightGBM “hộp đen” siêu mạnh mẽ trên toàn bộ không gian dữ liệu thô ban đầu, tinh chỉnh siêu tham số để tối ưu hóa tối đa năng lực bắt nợ xấu (chỉ số Recall).
- **Bước 2 (Chuyển giao tri thức):** Cho mô hình XGBoost Thầy này dự đoán trên toàn bộ tập dữ liệu huấn luyện để xuất ra một trường thông tin đặc trưng mới: Cột xác suất vỡ nợ liên tục nằm trong khoảng từ 0 đến 1 (Soft-labels / Probability of Default - PD).
- **Bước 3 (Mô hình Trò):** Lấy chính cột xác suất PD liên tục do ông thầy XGBoost vừa để ra để làm biến mục tiêu huấn luyện mới cho mô hình hồi quy Logistic Scorecard truyền thống.

Giá trị mang lại: Mô hình Scorecard học trò lúc này sẽ mô phỏng và “học mót” được toàn bộ các quy luật tương tác biến phi tuyến phức tạp ẩn mà ông thầy XGBoost quái vật đã khai phá được trong không gian dữ liệu, giúp nâng tầm hiệu suất của bảng điểm số nguyên truyền thống lên một đẳng cấp hoàn toàn mới mà không làm mất đi tính trực quan giải thích của hệ thống.

i Hướng mở rộng 3: Ứng dụng thuật toán EBM (Explainable Boosting Machine) để tạo “Tree Scorecard”

Cách thức thực hiện: Loại bỏ hoàn toàn toán học của hồi quy Logistic và cấu trúc mã hóa WoE phức tạp ra khỏi hệ thống pipeline. Thay vào đó, đưa trực tiếp dữ liệu thô vào huấn luyện bằng thuật toán EBM (Explainable Boosting Machine) do Microsoft Research phát triển.

Bản chất vận hành ngầm: EBM là thuật toán mô hình cây tăng cường (Boosting) được thiết kế dựa trên cấu trúc toán học của mô hình cộng tổng quát GA2M (Generalized Additive Models with Interactions). Điểm đặc thù tối tân của EBM là nó chỉ huấn luyện

các cây quyết định độc lập dạng hàm đơn biến cho từng đặc trưng riêng biệt và ngăn chặn hoàn toàn việc các cây tương tác chéo chồng chập lên nhau. Phương trình dự báo log-odds của EBM có dạng cộng tuyến tường minh:

$$g(E[Y]) = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_k(x_k)$$

Giá trị mang lại: Vì các hàm cấu trúc cây $f_i(x_i)$ hoạt động hoàn toàn độc lập tuyến tính và không có tương tác chéo bảo đảm nguyên lý cộng dồn, các thư viện mã nguồn mở hiện đại (như `interpret` của Microsoft) cho phép cấu hình xuất trực tiếp toàn bộ kết quả của mô hình mạng cây tăng cường này thành một bảng điểm số nguyên Scorecard tính tương tự như hồi quy Logistic. Đây là công nghệ tối tân nhất hiện nay trên thế giới: Mang lại độ chính xác quái vật của các mô hình học máy mạng cây hiện đại, nhưng lại sinh ra được file bảng điểm số nguyên trực quan 100% để chuyên viên tin dụng nhìn vào là hiểu ngay lý do vì sao hồ sơ bị từ chối cấp hạn mức.

XI. Tài liệu tham khảo

- [1] dbt Labs. “Connect postgres to dbt core”. [Online]. Available: <https://docs.getdbt.com/docs/local/connect-data-platform/postgres-setup>
- [2] dbt Labs. “About profiles.yml”. [Online]. Available: <https://docs.getdbt.com/docs/local/profiles.yml>
- [3] dbt Labs. “Add seeds to your dag”. [Online]. Available: <https://docs.getdbt.com/docs/build/seeds>
- [4] dbt Labs. “Add data tests to your dag”. [Online]. Available: <https://docs.getdbt.com/docs/build/data-tests>
- [5] dbt Labs. “About documentation”. [Online]. Available: <https://docs.getdbt.com/docs/build/documentation>